

02



TALLER DE INVESTIGACIÓN APLICADA

Diseño de instrumentos y calidad en la medición

Pablo Argote

Clase 2 · Mayo 2026 · Miércoles 13 · 6–9 PM

Recap: Clase 1



Del brief al diseño investigable

- | | | |
|-----------|-----------------------------|--|
| 01 | Leer el brief | Lo que el cliente dice y lo que falta. La inquietud rara vez llega en formato investigable. |
| 02 | Traducir a propuesta | Aclarar la decisión, distinguir lo importante de lo accesorio, detectar qué información falta. |
| 03 | Caso Banco X | Relanzamiento de producto financiero → 3 objetivos: segmentación, atributos, validación de claims. |
| 04 | Lo que NO hacer | Partir por la metodología, sobreofrecer, asumir que más detalle es más sofisticación. |

*Hoy bajamos al diseño: **a quién** preguntar, **qué** preguntar, y **cómo** preguntar mejor.*



HOY

Pregunta de la clase

¿Cómo traducir un concepto en preguntas que efectivamente capturen la decisión que importa?

BLOQUE 1

Muestreo

Probabilístico vs. targeteado · pesos del censo · cuándo sí, cuándo no

BLOQUE 2

Preguntas

Operacionalización · escalas · relevancia vs. posición · validación de claims

BLOQUE 3

Experimentos

Vignette · list experiment · conjoint · MaxDiff

** Habrá 2 breaks de 10 min*

01



BLOQUE 1

Muestreo: ¿a quién le preguntamos?

El ideal: muestreo probabilístico



Muestreo · 1 de 10

DEFINICIÓN

Cada unidad de la población tiene una probabilidad **conocida y mayor a cero** de ser seleccionada. Es la base de la inferencia estadística clásica.

- **Aleatoria simple:** cada unidad con la misma probabilidad; requiere marco muestral completo.

EJEMPLOS DEL GOLD STANDARD

Chile: **CASEN** (socioeconómica, MDS) y **CEP** (opinión pública). Colombia: **ECV del DANE**. Requieren marco muestral, presupuesto y tiempo — rara vez viables fuera del Estado o la academia.

El ideal: muestreo probabilístico



Muestreo · 1 de 10

DEFINICIÓN

Cada unidad de la población tiene una probabilidad **conocida y mayor a cero** de ser seleccionada. Es la base de la inferencia estadística clásica.

- **Aleatoria simple:** cada unidad con la misma probabilidad; requiere marco muestral completo.
- **Estratificada:** se divide en grupos (estratos) y se muestrea dentro de cada uno.

EJEMPLOS DEL GOLD STANDARD

Chile: **CASEN** (socioeconómica, MDS) y **CEP** (opinión pública). Colombia: **ECV del DANE**. Requieren marco muestral, presupuesto y tiempo — rara vez viables fuera del Estado o la academia.

El ideal: muestreo probabilístico



Muestreo · 1 de 10

DEFINICIÓN

Cada unidad de la población tiene una probabilidad **conocida y mayor a cero** de ser seleccionada. Es la base de la inferencia estadística clásica.

- **Aleatoria simple:** cada unidad con la misma probabilidad; requiere marco muestral completo.
- **Estratificada:** se divide en grupos (estratos) y se muestrea dentro de cada uno.
- **Por conglomerados:** se eligen “racimos” (manzanas, escuelas, hogares) y se entrevista a sus miembros.

EJEMPLOS DEL GOLD STANDARD

Chile: **CASEN** (socioeconómica, MDS) y **CEP** (opinión pública). Colombia: **ECV del DANE**. Requieren marco muestral, presupuesto y tiempo — rara vez viables fuera del Estado o la academia.

La realidad: muestras targeteadas



Muestreo · 2 de 10

OBSERVACIÓN

En investigación de mercado, el muestreo probabilístico casi nunca ocurre. La excepción son los estudios exploratorios que sí requieren una muestra representativa.

LO HABITUAL — muestras intencionadas

- **Paneles online:** usuarios que se inscribieron por incentivo; sesgan a quien tiene tiempo y conexión.

PREGUNTA SIEMPRE: ¿CÓMO SE GENERAN LOS DATOS?

¿Hay algo de aleatoriedad en el contacto? ¿O siempre responden los mismos? Si el proveedor recicla a los mismos usuarios, los sesgos quedan fijos en cada estudio.

La realidad: muestras targeteadas



Muestreo · 2 de 10

OBSERVACIÓN

En investigación de mercado, el muestreo probabilístico casi nunca ocurre. La excepción son los estudios exploratorios que sí requieren una muestra representativa.

LO HABITUAL — muestras intencionadas

- **Paneles online:** usuarios que se inscribieron por incentivo; sesgan a quien tiene tiempo y conexión.
- **Base de clientes:** CRM propio; útil pero solo cubre a quienes ya son clientes.

PREGUNTA SIEMPRE: ¿CÓMO SE GENERAN LOS DATOS?

¿Hay algo de aleatoriedad en el contacto? ¿O siempre responden los mismos? Si el proveedor recicla a los mismos usuarios, los sesgos quedan fijos en cada estudio.

La realidad: muestras targeteadas



Muestreo · 2 de 10

OBSERVACIÓN

En investigación de mercado, el muestreo probabilístico casi nunca ocurre. La excepción son los estudios exploratorios que sí requieren una muestra representativa.

LO HABITUAL — muestras intencionadas

- **Paneles online:** usuarios que se inscribieron por incentivo; sesgan a quien tiene tiempo y conexión.
- **Base de clientes:** CRM propio; útil pero solo cubre a quienes ya son clientes.
- **Snowball y referidos:** útil en targets difíciles, pero replican el mundo del primer contacto.

PREGUNTA SIEMPRE: ¿CÓMO SE GENERAN LOS DATOS?

¿Hay algo de aleatoriedad en el contacto? ¿O siempre responden los mismos? Si el proveedor recicla a los mismos usuarios, los sesgos quedan fijos en cada estudio.

¿Qué es ponderar?



Muestreo · 3 de 10

DEFINICIÓN

Ajuste **post-hoc** (después de recolectar) que asigna a cada usuario un peso w_g para que la muestra refleje la distribución conocida de la población.

REQUISITO

Necesita un **referente externo** con la distribución real: censo, registros administrativos. Sin eso, no hay contra qué ajustar.

FÓRMULA

Peso (una variable):

$$w_g = \frac{P_g^{\text{pob}}}{\hat{p}_g^{\text{mue}}}$$

proporción **poblacional** sobre proporción **muestral** en el grupo g

Rake (varias variables):

$$w_i = \prod_v \frac{P_v}{\hat{p}_v}$$

producto de los pesos por cada variable v , iterando hasta calzar todas las marginales

¿Cuándo se puede ponderar?



Muestreo · 4 de 10

LA PREGUNTA

Antes de ponderar, pregúnta: ¿mi muestra incluye **solo el target**, o también **observaciones fuera del target**?

A) MUESTRA CON OBS. FUERA DEL TARGET

Estudio amplio donde el target es un subgrupo (ej. clientes Banco X dentro de la población general). Hay no-clientes en la muestra.

Ponderar **SÍ** tiene sentido:

Conozco la proporción real target / no-target en la población (censo, registros), así que puedo corregir el submuestreo del target.

Útil para comparar target vs. no-target con la composición correcta.

B) MUESTRA ES SOLO EL TARGET

Filtré desde el inicio a clientes Banco X. Toda la muestra es target, no hay externos.

Ponderar **generalmente NO**:

El censo me dice cómo se distribuyen las demografías **en la población general**, no **dentro del target**. Aplicar pesos del censo asume que el target se parece al país.

¿Ponderar al censo? — caso Banco X



Muestreo · 5 de 10

SITUACIÓN

Estudio sobre clientes del Banco X. Ya son ~30 % de la población. Un cliente pregunta:
“¿Aplicamos pesos del censo (edad, sexo, NSE) para que los resultados sean representativos?”

POR QUÉ NO ES OBVIO

El target ya está concentrado demográficamente: clientes Banco X tienden a ser más urbanos, más jóvenes y de mayor SES. Esas son justamente las variables con las que el cliente quiere ponderar. Ajustar por algo que ya está **implicado** en la definición del target agrega poco.

LA REGLA QUE EMERGE

Mientras más correlacionada está una variable demográfica con la que define al target, **menos necesario** es ponderar por esa variable demográfica.

Cuándo sí ponderar



Muestreo · 6 de 10

CASO — Banco X en estudio amplio

Estudio cubre **toda la población** de consumidores. Banco X queda sub-representado: **10 % en muestra, 30 % en realidad.**

DOS OPCIONES

A) PONDERAR POR DEMOGRÁFICOS

Edad, urbanidad, SES (variables correlacionadas con ser cliente de Banco X). Rake weights con varias marginales del censo.

Asume que esas variables explican el sub-muestreo.

B) PONDERAR DIRECTO POR SER CLIENTE BANCO X

Indicador binario “cliente Banco X”. $w = P_g/p_g$:

Cientes Banco X: $0,30/0,10 = 3,0\times$

No clientes: $0,70/0,90 \approx 0,78\times$

CUIDADO: pesos altos sobre pocas observaciones inflan los errores estándar. Ponderar mucho con poca data hace *ruido*, no *precisión*.

Cuándo **SÍ** ayuda ponderar



Muestreo · 7 de 10

CONDICIONES

- **Independencia:** La variable de ponderación es **independiente** de lo que define al target.

La pregunta antes de ponderar: ¿esta variable agrega información que el target no me da ya?

Cuándo **SÍ** ayuda ponderar



Muestreo · 7 de 10

CONDICIONES

- **Independencia:** La variable de ponderación es **independiente** de lo que define al target.
- **Género:** Casi siempre seguro: rara vez correlaciona con la conducta o segmento que define el target.

La pregunta antes de ponderar: ¿esta variable agrega información que el target no me da ya?

Cuándo **SÍ** ayuda ponderar



Muestreo · 7 de 10

CONDICIONES

- **Independencia:** La variable de ponderación es **independiente** de lo que define al target.
- **Género:** Casi siempre seguro: rara vez correlaciona con la conducta o segmento que define el target.
- **Universo amplio:** Hay referente externo confiable (censo, registros) y la población definida es general.

La pregunta antes de ponderar: ¿esta variable agrega información que el target no me da ya?

Cuándo **SÍ** ayuda ponderar



Muestreo · 7 de 10

CONDICIONES

- **Independencia:** La variable de ponderación es **independiente** de lo que define al target.
- **Género:** Casi siempre seguro: rara vez correlaciona con la conducta o segmento que define el target.
- **Universo amplio:** Hay referente externo confiable (censo, registros) y la población definida es general.
- **Suficientes observaciones:** En cada celda hay n suficiente para que el peso no infle el error estándar.

La pregunta antes de ponderar: ¿esta variable agrega información que el target no me da ya?

Cuándo **NO** ayuda — ejemplo



Muestreo · 8 de 10

SETUP

Target: clientes Banco X. Decidimos ponderar por **educación**.

LOS DATOS — “educación media como máximo”

Censo (Chile): **40 %**

Muestra: **10 %**

Peso aplicado: **4×**

EL ERROR

Ese **40 %** describe a *toda* la población — no a los clientes Banco X. Dentro del target, la proporción con educación media **no sabemos cuál es**, y probablemente no es 40 %. Estamos ajustando con un dato que no aplica.

¿Cuándo sirven de verdad los pesos?



Muestreo · 9 de 10

LA IDEA

Ponderar por edad, sexo y NSE arregla desvíos de **mi muestra real vs. la muestra que pensé**.

También corrige **no-respuesta** cuando la demografía correlaciona con el outcome (ej.: jóvenes responden menos y opinan distinto).

Ej: encuesta de aprobación presidencial — ahí ponderar es **clave**, quiero ver al país completo.

NO SIRVE CUANDO

- El target es **específico** (no es “el país”).

¿Cuándo sirven de verdad los pesos?



Muestreo · 9 de 10

LA IDEA

Ponderar por edad, sexo y NSE arregla desvíos de **mi muestra real vs. la muestra que pensé**.

También corrige **no-respuesta** cuando la demografía correlaciona con el outcome (ej.: jóvenes responden menos y opinan distinto).

Ej: encuesta de aprobación presidencial — ahí ponderar es **clave**, quiero ver al país completo.

NO SIRVE CUANDO

- El target es **específico** (no es “el país”).
- El target está **correlacionado** con la variable demográfica.

¿Cuándo sirven de verdad los pesos?



Muestreo · 9 de 10

LA IDEA

Ponderar por edad, sexo y NSE arregla desvíos de **mi muestra real vs. la muestra que pensé**.

También corrige **no-respuesta** cuando la demografía correlaciona con el outcome (ej.: jóvenes responden menos y opinan distinto).

Ej: encuesta de aprobación presidencial — ahí ponderar es **clave**, quiero ver al país completo.

NO SIRVE CUANDO

- El target es **específico** (no es “el país”).
- El target está **correlacionado** con la variable demográfica.
- **No sabemos** cómo se distribuyen las demografías **dentro** del target.

Preguntas antes de ponderar



Muestreo · 10 de 10

a) ¿Cuánto me desvié de mi idea en la práctica?

Si hay desvío, sí. Ej: quería 30 % Banco X, llegué a 27 % → pondero por presencia de Banco X, nada más.

Preguntas antes de ponderar



Muestreo · 10 de 10

a) ¿Cuánto me desvié de mi idea en la práctica?

Si hay desvío, sí. Ej: quería 30 % Banco X, llegué a 27 % → pondero por presencia de Banco X, nada más.

b) ¿Es el target muy específico?

Mejor no.

Preguntas antes de ponderar



Muestreo · 10 de 10

a) ¿Cuánto me desvié de mi idea en la práctica?

Si hay desvío, sí. Ej: quería 30 % Banco X, llegué a 27 % → pondero por presencia de Banco X, nada más.

b) ¿Es el target muy específico?

Mejor no.

c) ¿Están las variables demográficas correlacionadas con el target?

Mejor no.

Preguntas antes de ponderar



Muestreo · 10 de 10

a) ¿Cuánto me desvié de mi idea en la práctica?

Si hay desvío, sí. Ej: quería 30 % Banco X, llegué a 27 % → pondero por presencia de Banco X, nada más.

b) ¿Es el target muy específico?

Mejor no.

c) ¿Están las variables demográficas correlacionadas con el target?

Mejor no.

d) ¿Conozco la distribución de las demográficas dentro del target?

Si no las conozco, o no tengo ninguna información, mejor no.

02



BLOQUE 2

Preguntas: de conceptos a ítems

*Una pincelada — el diseño de instrumentos es un campo entero. La idea fuerza: **las mejores preguntas obligan a priorizar**, no a evaluar en abstracto.*

¿Qué es operacionalizar?



Operacionalización · 1 de 4

DEFINICIÓN

Operacionalizar es **traducir un concepto abstracto en variables observables y medibles**.

- Los conceptos que importan en investigación rara vez se miden **directamente**.

Sin operacionalización, el instrumento mide cualquier cosa menos lo que queremos saber.

¿Qué es operacionalizar?



Operacionalización · 1 de 4

DEFINICIÓN

Operacionalizar es **traducir un concepto abstracto en variables observables y medibles**.

- Los conceptos que importan en investigación rara vez se miden **directamente**.
- “Satisfacción”, “confianza”, “lealtad”, “intención de compra” no vienen con una **unidad de medida obvia**.

Sin operacionalización, el instrumento mide cualquier cosa menos lo que queremos saber.

¿Qué es operacionalizar?



Operacionalización · 1 de 4

DEFINICIÓN

Operacionalizar es **traducir un concepto abstracto en variables observables y medibles**.

- Los conceptos que importan en investigación rara vez se miden **directamente**.
- “Satisfacción”, “confianza”, “lealtad”, “intención de compra” no vienen con una **unidad de medida obvia**.
- Operacionalizar es el **punto** entre la pregunta de investigación y los datos.

Sin operacionalización, el instrumento mide cualquier cosa menos lo que queremos saber.

No es trivial



Operacionalización · 2 de 4

PREGUNTA DE INVESTIGACIÓN

¿Qué tan satisfechos están los usuarios con el servicio?

- “En una escala de 1 a 10, ¿cuán satisfecho está con el servicio?”

escala global

OBSERVACIÓN

Cada operacionalización captura algo distinto. Elegir mal el indicador puede llevar a conclusiones equivocadas con datos perfectamente recolectados.

No es trivial



Operacionalización · 2 de 4

PREGUNTA DE INVESTIGACIÓN

¿Qué tan satisfechos están los usuarios con el servicio?

- “En una escala de 1 a 10, ¿cuán satisfecho está con el servicio?”
- “¿Qué tan probable es que recomiende el servicio? (0–10)”

escala global

NPS

OBSERVACIÓN

Cada operacionalización captura algo distinto. Elegir mal el indicador puede llevar a conclusiones equivocadas con datos perfectamente recolectados.

No es trivial



Operacionalización · 2 de 4

PREGUNTA DE INVESTIGACIÓN

¿Qué tan satisfechos están los usuarios con el servicio?

- “En una escala de 1 a 10, ¿cuán satisfecho está con el servicio?” *escala global*
- “¿Qué tan probable es que recomiende el servicio? (0–10)” *NPS*
- “¿Volvería a contratar el servicio?” *intención de comportamiento*

OBSERVACIÓN

Cada operacionalización captura algo distinto. Elegir mal el indicador puede llevar a conclusiones equivocadas con datos perfectamente recolectados.

No es trivial



Operacionalización · 2 de 4

PREGUNTA DE INVESTIGACIÓN

¿Qué tan satisfechos están los usuarios con el servicio?

- “En una escala de 1 a 10, ¿cuán satisfecho está con el servicio?” *escala global*
- “¿Qué tan probable es que recomiende el servicio? (0–10)” *NPS*
- “¿Volvería a contratar el servicio?” *intención de comportamiento*
- “¿Cuántas veces ha contactado al servicio en los últimos 6 meses?” *conducta revelada*

OBSERVACIÓN

Cada operacionalización captura algo distinto. Elegir mal el indicador puede llevar a conclusiones equivocadas con datos perfectamente recolectados.

No es trivial



Operacionalización · 2 de 4

PREGUNTA DE INVESTIGACIÓN

¿Qué tan satisfechos están los usuarios con el servicio?

- “En una escala de 1 a 10, ¿cuán satisfecho está con el servicio?” *escala global*
- “¿Qué tan probable es que recomiende el servicio? (0–10)” *NPS*
- “¿Volvería a contratar el servicio?” *intención de comportamiento*
- “¿Cuántas veces ha contactado al servicio en los últimos 6 meses?” *conducta revelada*
- “¿Cómo describiría su última experiencia?” *narrativa abierta*


OBSERVACIÓN

Cada operacionalización captura algo distinto. Elegir mal el indicador puede llevar a conclusiones equivocadas con datos perfectamente recolectados.

El pipeline



Operacionalización · 3 de 4



* **Dimensiones** es opcional: si el concepto ya es concreto (ej. “frecuencia de compra”), se salta directo a indicadores.

EJEMPLO — “Confianza en la marca”

Dimensiones fiabilidad · honestidad · cercanía

Indicadores percepción de cumplimiento · transparencia · trato

Ítems “¿Cuán de acuerdo está con que la marca cumple lo que promete?” (Likert 1–5)

Tipos de preguntas



Operacionalización · 4 de 4

CERRADAS — para medir

- 01 Sí o No (dicotómica)
- 02 Opción múltiple (única o múltiple)
- 03 Likert (acuerdo o frecuencia)
- 04 Diferencial semántico (dos polos)
- 05 Ranking (priorización)
- 06 Numérica (edad, ingreso, NPS)

ABIERTAS — para explorar

- 01 Respuesta corta libre
- 02 Respuesta extendida
- 03 Asociación espontánea
- 04 Completación de frases

*Las abiertas dan riqueza, pero son **engorrosas**: caras de codificar, difíciles de comparar y muy ruidosas. Úsalas con cuidado.*

Ejemplo: **Sí o No**



Cuándo funciona y cuándo no

MALA PREGUNTA

“¿Cree usted que se debe cuidar el medio ambiente?”

→ 95 % dice “sí”. Mide **deseabilidad social pura**, no aporta información para decidir.

BUENA PREGUNTA

“¿Recicló usted en su hogar al menos una vez la semana pasada?”

→ Conducta concreta y verificable. Discrimina entre quienes lo hacen y quienes no.

*Sí/No solo sirve para **hechos verificables**, no para opiniones generales.*

Ejemplo: Likert



Actitudes graduales

LA PREGUNTA

“¿Qué tan de acuerdo está con la frase: esta marca cumple lo que promete?”

ESCALA



1

muy en desacuerdo



2



3



4



5

muy de acuerdo

CUÁNDO USAR — Y EL LÍMITE

Útil para actitudes y opiniones graduales. **Pero comparte sesgos con la dicotómica:** si todos los ítems son “positivos”, la gente responde 4 o 5 a casi todo, sin discriminar.

Diferencial semántico



Dos polos con punto medio

CÓMO SE VE

Se presentan dos adjetivos opuestos y el usuario se ubica entre ambos.

Confiable	☐	☐	☐	☐	☐	Poco confiable
Moderno	☐	☐	☐	☐	☐	Anticuado
Caro	☐	☐	☐	☐	☐	Económico

EJEMPLO — AFP

“¿Aprueba las AFP?” → “no, son los malos”. Con diferencial *100 % estatal* ↔ *100 % privado*: la gente se ubica al medio — aparece el matiz real.

- Captura **matiz/gradiente** entre dos polos — ideal para percepciones de marca y posicionamiento.

Diferencial semántico



Dos polos con punto medio

CÓMO SE VE

Se presentan dos adjetivos opuestos y el usuario se ubica entre ambos.

Confiable	☐	☐	☐	☐	☐	Poco confiable
Moderno	☐	☐	☐	☐	☐	Anticuado
Caro	☐	☐	☐	☐	☐	Económico

EJEMPLO — AFP

“¿Aprueba las AFP?” → “no, son los malos”. Con diferencial *100 % estatal* ↔ *100 % privado*: la gente se ubica al medio — aparece el matiz real.

- Captura **matiz/gradiente** entre dos polos — ideal para percepciones de marca y posicionamiento.
- El punto medio no es “no sé”: es indiferencia o equidistancia.

Diferencial semántico



Dos polos con punto medio

CÓMO SE VE

Se presentan dos adjetivos opuestos y el usuario se ubica entre ambos.

Confiable	☐	☐	☐	☐	☐	Poco confiable
Moderno	☐	☐	☐	☐	☐	Anticuado
Caro	☐	☐	☐	☐	☐	Económico

EJEMPLO — AFP

“¿Aprueba las AFP?” → “no, son los malos”. Con diferencial *100 % estatal* ↔ *100 % privado*: la gente se ubica al medio — aparece el matiz real.

- Captura **matiz/gradiente** entre dos polos — ideal para percepciones de marca y posicionamiento.
- El punto medio no es “no sé”: es indiferencia o equidistancia.
- Si los adjetivos no son verdaderos opuestos, la escala se rompe.

Ejemplo: Ranking



Forzar a priorizar — la joya

LA PREGUNTA

*“Ordene de **más** a **menos** importante al elegir un banco:”*

1. Tasa preferencial
2. Atención rápida en sucursal
3. Plataforma digital fácil de usar
4. Sucursales cercanas

*El usuario no puede decir “todos son importantes”. Tiene que **ceder algo** — y eso es lo que revela qué pesa de verdad.*

Posición vs. relevancia



Una distinción clave

POSICIÓN

- ¿Qué **piensa** el usuario?
- ¿Está a favor o en contra?
- ¿Qué tan de acuerdo está?
- Se mide bien con **Likert**.

RELEVANCIA

- ¿Cuánto le **importa de verdad**?
- ¿Pesa en su **decisión**?
- ¿**Sacrificaría** otra cosa por esto?
- Se mide bien con **priorización forzada**.

LA TRAMPA — ejemplo, ciencia política

“¿Le importa el orden público?” → casi todos dicen que sí.

“¿Orden público o libertad individual?” → **revela qué pesa de verdad**.

Medir solo posición confunde “importante en abstracto” con “decisivo en la práctica”.

Ejemplo intuitivo



Posición vs. relevancia · caso ilustrativo

PREGUNTA 1 — POSICIÓN

“¿Está de acuerdo con que la sustentabilidad ambiental de una empresa es importante?”

Respuesta típica: ~90 % “muy de acuerdo”.

PREGUNTA 2 — RELEVANCIA

“Cuando elige entre dos productos similares, ¿qué pesa más en su decisión: precio, marca, sustentabilidad o conveniencia?”

Respuesta típica: sustentabilidad queda 4ª, con ~5 %.

La gente **piensa** que la sustentabilidad importa (posición). Pero al **decidir**, compra por precio (relevancia baja).

Preguntas mal formuladas



Anti-ejemplos · 1 de 2

“¿Cree usted que se debe cuidar el medio ambiente?”

respuesta obvia (~95,% sí); no aporta información, mide deseabilidad social pura.

“¿Está usted de acuerdo con la gestión del gobierno?”

¿qué gestión? ¿en qué área? mide aprobación general, no la decisión que importa.

“¿Cree que el país va por buen camino?”

“buen camino” significa cosas distintas para distintas personas.

“¿No le parece preocupante el alza de la delincuencia?”

pregunta cargada con doble negación; sesga hacia “sí”.

“¿Aprobaría una reforma tributaria que aumente la recaudación para programas sociales?”

premisa cargada; cambia si se describe como “aumento de impuestos”.

Preguntas mal formuladas



Anti-ejemplos · 2 de 2

“¿Qué importancia le asigna a la educación, la salud y la seguridad?”

mide posición (todo importa); no fuerza priorización, no sirve para decidir.

“¿Cuán satisfecho está con su vida en general?”

tan global que no se puede accionar; mejor preguntar por dimensiones específicas.

“¿Recomendaría este producto a sus amigos y familiares?”

doble pregunta (¿amigos? ¿familiares?). NPS resuelve preguntando solo “a un amigo”.

“En su opinión, ¿los inmigrantes contribuyen positivamente al país?”

tema sensible → deseabilidad social fuerte; mejor usar viñeta o list experiment.

Patrón común: miden posición sin captar relevancia, cargan la respuesta, o son demasiado vagas para accionar.

Caso Banco X — aplicación



Validar claims para un producto financiero

CONTEXTO — 4 claims a validar

- “Tasa preferencial garantizada por 12 meses.”
- “Sin costos de mantención el primer año.”
- “Aprobación 100 % online en menos de 24 horas.”
- “Respaldado por el banco más grande del país.”

PROBLEMA — Likert

“¿Cuán importante es X?” → los 4 claims salen **entre 4 y 5**. Imposible priorizar.

SOLUCIÓN — forzar a priorizar

Pedir al usuario que elija **cuál claim importa más** y cuál menos. La elección forzada revela la prioridad real.


Mismo patrón que las AFP: el sí/no o Likert directo aplasta el matiz; el trade-off captura qué importa de verdad.

El resultado en Banco X



Validación de claims · priorización forzada

IMPORTANCIA RELATIVA




- Si hubiéramos preguntado solo en Likert, los cuatro habrían quedado entre 4 y 5.

El resultado en Banco X



Validación de claims · priorización forzada

IMPORTANCIA RELATIVA




- Si hubiéramos preguntado solo en Likert, los cuatro habrían quedado entre 4 y 5.
- Forzar la priorización nos permitió ordenar y descartar con criterio cuantitativo.

El resultado en Banco X



Validación de claims · priorización forzada

IMPORTANCIA RELATIVA



- Si hubiéramos preguntado solo en Likert, los cuatro habrían quedado entre 4 y 5.
- Forzar la priorización nos permitió ordenar y descartar con criterio cuantitativo.
- La decisión de comunicación se basó en el Claim A, no en intuición.

03



BLOQUE 3

Experimentos para mejorar la medición

*Para reducir sesgos y captar lo que importa — **no** para estudiar relaciones causa-efecto. La causalidad real no se resuelve dentro de una encuesta.*

¿Por qué no basta con preguntar?



Sesgos de las preguntas directas

EL PROBLEMA

Aun con buena operacionalización y escalas correctas, las preguntas directas tienen **sesgos sistemáticos**.

- **Deseabilidad social:** se reporta lo socialmente aceptable, no lo real.

*La salida es captar preferencias de forma **indirecta**, vía experimentos dentro de la encuesta.*

¿Por qué no basta con preguntar?



Sesgos de las preguntas directas

EL PROBLEMA

Aun con buena operacionalización y escalas correctas, las preguntas directas tienen **sesgos sistemáticos**.

- **Deseabilidad social:** se reporta lo socialmente aceptable, no lo real.
- **Anclaje y framing:** la respuesta cambia con cómo se presenta la pregunta.

*La salida es captar preferencias de forma **indirecta**, vía experimentos dentro de la encuesta.*

¿Por qué no basta con preguntar?



Sesgos de las preguntas directas

EL PROBLEMA

Aun con buena operacionalización y escalas correctas, las preguntas directas tienen **sesgos sistemáticos**.

- **Deseabilidad social:** se reporta lo socialmente aceptable, no lo real.
- **Anclaje y framing:** la respuesta cambia con cómo se presenta la pregunta.
- **Falta de introspección:** el usuario no siempre sabe por qué decide lo que decide.

*La salida es captar preferencias de forma **indirecta**, vía experimentos dentro de la encuesta.*

¿Por qué no basta con preguntar?



Sesgos de las preguntas directas

EL PROBLEMA

Aun con buena operacionalización y escalas correctas, las preguntas directas tienen **sesgos sistemáticos**.

- **Deseabilidad social:** se reporta lo socialmente aceptable, no lo real.
- **Anclaje y framing:** la respuesta cambia con cómo se presenta la pregunta.
- **Falta de introspección:** el usuario no siempre sabe por qué decide lo que decide.
- **Trade-offs invisibles:** “todo me importa” cuando se pregunta una cosa a la vez.

*La salida es captar preferencias de forma **indirecta**, vía experimentos dentro de la encuesta.*

Captar preferencias indirectamente



4 técnicas que veremos hoy

IDEA CENTRAL

En lugar de preguntar “¿qué le importa?”, se construye una situación donde el usuario **revela** sus preferencias al **elegir, evaluar o decidir**. **Objetivo: mejor medición, no inferencia causal.**

01 Vignette

escenarios randomizados

02 List experiment

prevalencia de conductas sensibles

03 Conjoint

trade-offs entre múltiples atributos

04 MaxDiff

priorización forzada entre alternativas

QUÉ ES

Se presenta un escenario corto cuyos atributos **varían aleatoriamente** entre usuarios. La diferencia en las respuestas estima el **efecto del atributo** en la evaluación.

VERSIÓN A

“**María**, ingeniera, 32 años, egresada de universidad **pública**, 5 años de experiencia. ¿Qué tan apta para el cargo?”

VERSIÓN B

“**Pedro**, ingeniero, 32 años, egresado de universidad **privada**, 5 años de experiencia. ¿Qué tan apto para el cargo?”

- Se aísla el efecto de género y tipo de universidad.

QUÉ ES

Se presenta un escenario corto cuyos atributos **varían aleatoriamente** entre usuarios. La diferencia en las respuestas estima el **efecto del atributo** en la evaluación.

VERSIÓN A

“**María**, ingeniera, 32 años, egresada de universidad **pública**, 5 años de experiencia. ¿Qué tan apta para el cargo?”

VERSIÓN B

“**Pedro**, ingeniero, 32 años, egresado de universidad **privada**, 5 años de experiencia. ¿Qué tan apto para el cargo?”

- Se aísla el efecto de género y tipo de universidad.
- El usuario no sabe que existe otra versión → reduce deseabilidad social.

QUÉ ES

Se presenta un escenario corto cuyos atributos **varían aleatoriamente** entre usuarios. La diferencia en las respuestas estima el **efecto del atributo** en la evaluación.

VERSIÓN A

“**María**, ingeniera, 32 años, egresada de universidad **pública**, 5 años de experiencia. ¿Qué tan apta para el cargo?”

VERSIÓN B

“**Pedro**, ingeniero, 32 años, egresado de universidad **privada**, 5 años de experiencia. ¿Qué tan apto para el cargo?”

- Se aísla el efecto de género y tipo de universidad.
- El usuario no sabe que existe otra versión → reduce deseabilidad social.
- Útil cuando: hay sospecha de sesgo, prejuicio, o el atributo es difícil de declarar.

Deseabilidad social



Cuando la respuesta no coincide con la conducta

EL SESGO

El usuario reporta lo **socialmente aceptable**, no lo que efectivamente piensa o hace.

CASO CLÁSICO — participación electoral en Chile

CEP / encuestas pre-electorales: ~70 % declara que va a votar.

Servel · participación real: ~45 % efectivamente vota.

La diferencia (~25 pp) no es error muestral: es deseabilidad social. Votar es “lo correcto”.

- Otros ejemplos: reciclaje, donación, lectura, ejercicio, consumo de alcohol.

Deseabilidad social



Cuando la respuesta no coincide con la conducta

EL SESGO

El usuario reporta lo **socialmente aceptable**, no lo que efectivamente piensa o hace.

CASO CLÁSICO — participación electoral en Chile

CEP / encuestas pre-electorales: ~70 % declara que va a votar.

Servel · participación real: ~45 % efectivamente vota.

La diferencia (~25 pp) no es error muestral: es deseabilidad social. Votar es “lo correcto”.

- Otros ejemplos: reciclaje, donación, lectura, ejercicio, consumo de alcohol.
- Mientras más normativa la conducta, mayor el sesgo.

Deseabilidad social



Cuando la respuesta no coincide con la conducta

EL SESGO

El usuario reporta lo **socialmente aceptable**, no lo que efectivamente piensa o hace.

CASO CLÁSICO — participación electoral en Chile

CEP / encuestas pre-electorales: ~70 % declara que va a votar.

Servel · participación real: ~45 % efectivamente vota.

La diferencia (~25 pp) no es error muestral: es deseabilidad social. Votar es “lo correcto”.

- Otros ejemplos: reciclaje, donación, lectura, ejercicio, consumo de alcohol.
- Mientras más normativa la conducta, mayor el sesgo.
- No se elimina con buena redacción: hay que diseñar la medición de otra manera — como el **list experiment** (siguiente).

List experiment



Técnicas indirectas · 2 de 4

QUÉ ES

Técnica para medir la **prevalencia** de una conducta u opinión sensible **sin que el usuario revele individualmente** su respuesta.

MECÁNICA — dos grupos randomizados

- **Control:** *"Indique cuántas de las siguientes le pasaron en el último año:"* + 3 actividades cotidianas (cambió de empleo, viajó al extranjero, donó a alguna causa).

ESTIMACIÓN

Diferencia de medias entre grupos = prevalencia del ítem sensible. Útil cuando: discriminación, conductas ilegales, opiniones tabú.

List experiment



Técnicas indirectas · 2 de 4

QUÉ ES

Técnica para medir la **prevalencia** de una conducta u opinión sensible **sin que el usuario revele individualmente** su respuesta.

MECÁNICA — dos grupos randomizados

- **Control:** *“Indique cuántas de las siguientes le pasaron en el último año:”* + 3 actividades cotidianas (cambió de empleo, viajó al extranjero, donó a alguna causa).
- **Tratamiento:** Las mismas 3 + el ítem sensible (ej.: **“recibió un pago de alguien vinculado al narcotráfico”**).

ESTIMACIÓN

Diferencia de medias entre grupos = prevalencia del ítem sensible. Útil cuando: discriminación, conductas ilegales, opiniones tabú.

List experiment



Técnicas indirectas · 2 de 4

QUÉ ES

Técnica para medir la **prevalencia** de una conducta u opinión sensible **sin que el usuario revele individualmente** su respuesta.

MECÁNICA — dos grupos randomizados

- **Control:** *“Indique cuántas de las siguientes le pasaron en el último año:”* + 3 actividades cotidianas (cambió de empleo, viajó al extranjero, donó a alguna causa).
- **Tratamiento:** Las mismas 3 + el ítem sensible (ej.: **“recibió un pago de alguien vinculado al narcotráfico”**).
- **Reporte:** El usuario solo dice **cuántas** le pasaron, no cuáles.

ESTIMACIÓN

Diferencia de medias entre grupos = prevalencia del ítem sensible. Útil cuando: discriminación, conductas ilegales, opiniones tabú.

QUÉ ES

Se presentan dos perfiles reales del producto y el usuario elige uno. La idea: la preferencia surge de una **elección concreta entre alternativas**, no de evaluar atributos en abstracto. Repitiendo, se estima la **preferencia por cada atributo por separado**.

PRODUCTO FINANCIERO

Atributo	Opción 1	Opción 2
Tasa	4, %	7, %
Monto mínimo	\$500	\$5.000
Plazo	3 meses	12 meses
Aprobación	24 hrs	5 días

¿Cuál preferiría contratar?

Cada elección es un trade-off real: prefiero tasa baja a costa de un plazo más largo. Eso revela el peso de cada atributo.

QUÉ ES

Se presentan subconjuntos de ítems (típicamente 4 a la vez); el usuario elige el más importante y el menos importante. Se repite varias veces.

CLAIMS BANCO X

De los siguientes beneficios, ¿cuál es el más importante y cuál el menos importante?

- Tasa preferencial garantizada por 12 meses

Estima utilidad relativa por ítem; escalable a 15–20 claims.

QUÉ ES

Se presentan subconjuntos de ítems (típicamente 4 a la vez); el usuario elige el más importante y el menos importante. Se repite varias veces.

CLAIMS BANCO X

De los siguientes beneficios, ¿cuál es el más importante y cuál el menos importante?

- Tasa preferencial garantizada por 12 meses
- Sin costos de mantención el primer año

Estima utilidad relativa por ítem; escalable a 15–20 claims.

QUÉ ES

Se presentan subconjuntos de ítems (típicamente 4 a la vez); el usuario elige el más importante y el menos importante. Se repite varias veces.

CLAIMS BANCO X

De los siguientes beneficios, ¿cuál es el más importante y cuál el menos importante?

- Tasa preferencial garantizada por 12 meses
- Sin costos de mantención el primer año
- Aprobación 100,% online en menos de 24 horas

Estima utilidad relativa por ítem; escalable a 15–20 claims.

QUÉ ES

Se presentan subconjuntos de ítems (típicamente 4 a la vez); el usuario elige el más importante y el menos importante. Se repite varias veces.

CLAIMS BANCO X

De los siguientes beneficios, ¿cuál es el más importante y cuál el menos importante?

- Tasa preferencial garantizada por 12 meses
- Sin costos de mantención el primer año
- Aprobación 100,% online en menos de 24 horas
- Respaldo por el banco más grande del país

Estima utilidad relativa por ítem; escalable a 15–20 claims.

¿Cuándo usar cuál?



Decisión rápida · resumen

Técnica	Pregunta que responde	Cuándo
Vignette	¿Qué efecto tiene un atributo en una evaluación?	Sospecha de sesgo o prejuicio.
List experiment	¿Qué proporción hace o piensa X (sensible)?	Conductas tabú o no declarables.
Conjoint	¿Cuánto pesa cada atributo en la elección?	Diseño de productos con múltiples atributos.
MaxDiff	¿Qué importa más entre N alternativas?	Priorización de claims, mensajes, prioridades.

PUNTO COMÚN

Todas combinan aleatorización (lógica experimental) con encuesta (representatividad).



Lo que aprendimos · próximo paso

HOY

- Operacionalizar concepto → variable.

PRÓXIMA CLASE

- Producción y análisis de datos.
- Software, IA, calidad de datos.
- Martes 19 de mayo · 6–9 PM



Lo que aprendimos · próximo paso

HOY

- Operacionalizar concepto → variable.
- Tipos de preguntas: sí o no, Likert, ranking, diferencial semántico.

PRÓXIMA CLASE

- Producción y análisis de datos.
- Software, IA, calidad de datos.
- Martes 19 de mayo · 6–9 PM



Lo que aprendimos · próximo paso

HOY

- Operacionalizar concepto → variable.
- Tipos de preguntas: sí o no, Likert, ranking, diferencial semántico.
- Distinguir **posición** de **relevancia**.

PRÓXIMA CLASE

- Producción y análisis de datos.
- Software, IA, calidad de datos.
- Martes 19 de mayo · 6–9 PM



Lo que aprendimos · próximo paso

HOY

- Operacionalizar concepto → variable.
- Tipos de preguntas: sí o no, Likert, ranking, diferencial semántico.
- Distinguir **posición** de **relevancia**.
- Validar claims con MaxDiff (caso Banco X).

PRÓXIMA CLASE

- Producción y análisis de datos.
- Software, IA, calidad de datos.
- Martes 19 de mayo · 6–9 PM

- Validar claims con MaxDiff (caso Banco X).
- Captar preferencias indirectamente: vignette, list, conjoint, Max-Diff.